

LAPORAN TEKNIS KOMPREHENSIF DATA SCIENCE

ResuMy

BAB 1: PENDAHULUAN

1.1 Latar Belakang dan Problem Discovery

Industri teknologi informasi (IT) di Indonesia dan dunia mengalami transformasi yang sangat pesat. Setiap tahun, ribuan posisi pekerjaan baru muncul dengan persyaratan kompetensi teknis yang terus berkembang. Di sisi lain, para pencari kerja menghadapi tantangan nyata dalam memahami keahlian apa yang benar-benar dibutuhkan oleh industri saat ini. Kondisi ini menciptakan sebuah fenomena yang dikenal sebagai skill gap, yaitu kesenjangan antara keahlian yang dimiliki oleh kandidat dan keahlian yang dibutuhkan oleh perusahaan.

Dalam proses problem discovery, tim melakukan analisis terhadap berbagai permasalahan yang terjadi di ekosistem rekrutmen IT, di antaranya:

- Tingginya tingkat penolakan kandidat IT pada tahap screening awal akibat ketidaksesuaian antara isi CV dengan kebutuhan skill pada job description.
- Banyak kandidat memiliki kemampuan yang relevan, namun gagal terdeteksi oleh sistem ATS karena tidak menggunakan kata kunci atau struktur yang sesuai.

1.2 Solusi Utama

Berdasarkan hasil analisis masalah di atas, tim memutuskan untuk mengembangkan satu solusi utama yaitu ResuMy. ResuMy hadir sebagai solusi berupa sistem ATS Scoring Engine dan Skill Gap Analyzer berbasis Deep Learning, dilengkapi dengan Dashboard analisis tren skill IT. Sistem ini mampu menghitung tingkat kecocokan antara CV dan job description menggunakan pendekatan semantic similarity, serta mengidentifikasi skill yang sudah sesuai maupun yang masih kurang berdasarkan Named Entity Recognition (NER).

BAB 2: METODOLOGI DATA

2.1 Gambaran Umum Alur Kerja Data (Data Wrangling)

Proses data wrangling pada proyek ini dilakukan secara menyeluruh (end-to-end) menggunakan ekosistem Python, mencakup tiga fase utama: Gathering, Assessing, dan Cleaning. Seluruh proses didokumentasikan dalam notebook `Cleaning_Dataset.ipynb` dan `EDA_Capstone.ipynb`.

Library Utama yang Digunakan:

- Pandas
- numpy
- re
- ast
- os
- sklearn.model_selection (train_test_split)
- datasets
- gdown
- matplotlib
- seaborn
- plotly

2.2 Gathering Data

Dataset proyek bersumber dari dua sumber data publik yang berbeda yang mencakup dua entitas utama: Job Description (JD) dan Curriculum Vitae (CV).

2.2.1 Dataset Job Description (JD)

Dataset JD diperoleh dari platform Kaggle dalam format .csv. Dataset ini berisi 2.098 lowongan pekerjaan yang dikategorikan ke dalam 18 role industri IT, mencakup domain seperti Data Scientist, Machine Learning Engineer, Web Developer, Cloud Architect, Cyber Security Analyst, dan lain-lain.

```
file_jd = '13_tLGL1b2Drk6F-ep9Xc3_wTzrzydrJh'  
url_jd = f'https://drive.google.com/uc?id={file_jd}'  
df = pd.read_csv(url_jd)
```

2.2.2 Dataset Curriculum Vitae (CV)

Dataset CV dikumpulkan dari tiga sumber yang kemudian digabungkan menjadi satu dataset terpadu:

- **CV 1 (df_cv1):** Diperoleh dari HuggingFace Datasets (InferencePrince555/Resume-Dataset). Mencakup 5 role IT: Database Administrator, Network Administrator, Security Analyst, Systems Administrator, Web Developer.
- **CV 2 (df_cv2):** Diperoleh dari Kaggle. Mencakup role Business Analyst, Data Engineer, dan BI Analyst.
- **CV 3 (df_cv3):** Diperoleh dari Kaggle. Mencakup role Data Scientist, Machine Learning Engineer, dan Cloud Engineer.

Setelah penggabungan ketiga sumber, total dataset CV terdiri dari 17.220 dokumen yang terbagi dalam 11 role berbeda.

2.3 Assessing Data

Pada fase ini, tim melakukan penilaian kualitas data secara sistematis pada setiap tabel sebelum proses pembersihan dilakukan.

Temuan Penilaian pada Dataset JD:

- Kolom Query (nama role) dan Description (teks JD) tidak memiliki missing value.
- Terdapat beberapa baris dengan deskripsi pekerjaan yang sangat pendek atau tidak relevan.
- Kolom Education, Experience, dan Token Usage dinilai tidak relevan untuk pemodelan dan analisis karena sangat banyak missing value pada kolom tersebut.

Temuan Penilaian pada Dataset CV:

- Terdapat kandidat yang tidak mencantumkan skill teknis secara eksplisit dalam teks CV mereka.
- Terdapat duplikasi konten CV yang perlu dihilangkan.
- Nama kolom antar ketiga sumber berbeda-beda dan perlu distandarisasi.

2.4 Fase 3: Cleaning Data

2.4.1 Penyesuaian Struktur Kolom dan Pemetaan Role

Seluruh nama kolom distandarisasi secara konsisten. Nama-nama role pada setiap dataset dipetakan ke dalam kategori yang seragam.

```
df = df.rename(columns={
    'ID'      : 'job_id',
    'Query'   : 'industry_domain',
    'Job Title': 'job_title',
    'Description': 'job_desc_text',
    'IT Skills': 'required_skills',
    'Soft Skills': 'soft_skills',
})
df = df.drop(columns=['Education', 'Experience', 'Token Usage'])
```

2.4.2 Fungsi Pembersihan Teks

Fungsi ini diterapkan secara konsisten pada kolom teks dari kedua dataset untuk menghilangkan noise yang dapat mengganggu performa analisis dan pemodelan.

```
def clean_text_universal(text):
    if pd.isna(text): return ""
    text = re.sub(r'http\S+|www\S+', "", text) # hapus URL
    text = re.sub(r'<.*?>', "", text)         # hapus tag HTML
    text = text.lower()                        # normalisasi huruf kecil
    text = re.sub(r'\s+', ' ', text).strip()   # normalisasi whitespace
    return text
```

2.4.3 Deduplikasi dan Validasi Data

Proses deduplikasi dilakukan berdasarkan kolom job_desc_text (untuk JD) dan cv_text (untuk CV) untuk memastikan tidak ada data ganda yang membiaskan analisis. Baris dengan job_desc_text kosong dihapus sepenuhnya.

2.4.4 Ekstraksi Skill Menggunakan Daftar Entitas Terkurasi

Tim data science membangun daftar entitas IT (IT Skills List) yang mencakup lebih dari 250 skill unik dari berbagai kategori: bahasa pemrograman, framework web, basis data, platform cloud, alat analitik, keamanan siber, dan metodologi proyek. Ekstraksi skill dilakukan menggunakan pendekatan pattern matching berbasis ekspresi reguler (regex).

```
def extract_skills(text):
    text_lower = text.lower()
    found = []
    for skill in IT_SKILLS_LIST:
        pattern = rf'\b{re.escape(skill)}\b'
        if re.search(pattern, text_lower):
```

```
found.append(skill)
return found
```

2.4.5 Pembagian Dataset (Train-Test Split)

Seluruh dataset dibagi menjadi data latih dan data uji dengan rasio 80:20 menggunakan stratified sampling berdasarkan kolom kategori role.

```
jd_train, jd_test = train_test_split(
    df_model, test_size=0.2, random_state=42,
    stratify=df_model['industry_domain']
)
```

2.4.6 BIO Tagging untuk Pengenalan Entitas (Model NER)

Untuk keperluan pemodelan NER, teks mentah dikonversi menjadi format token berlabel menggunakan skema BIO (Beginning-Inside-Outside). Setiap token dilabeli sebagai B-SKILL (token pertama sebuah skill), I-SKILL (token lanjutan skill dengan lebih dari 1 kata), dan O (bukan skill).

2.4.7 Konstruksi Dataset Pasangan CV-JD (Model Siamese)

Dataset untuk pemodelan dibangun dengan membentuk pasangan antara dokumen CV dan JD, dilengkapi dengan label kecocokan: 1 (Match/Positif) dan 0 (Tidak Match/Negatif). Salah satu kriteria seleksi pasangan positif adalah menggunakan ambang batas minimum Skill Overlap sebesar 5 skill yang sama.

2.5 Data Dictionary

Tabel 1: Dataset Job Description (jd_train.csv / jd_test.csv)

Nama Kolom	Tipe Data	Deskripsi	Contoh Nilai
job_id	Integer	Identitas unik setiap lowongan pekerjaan	1001
industry_domain	String	Kategori/domain role industri IT	Data Scientist
job_title	String	Judul spesifik posisi pekerjaan	Senior Data Scientist
job_desc_text	String	Teks deskripsi pekerjaan (telah dibersihkan)	we are looking for a...
required_skills	String	Daftar skill teknis yang dibutuhkan (format CSV)	python, sql, tableau

Tabel 2: Dataset CV (cv_train.csv / cv_test.csv)

Nama Kolom	Tipe Data	Deskripsi	Contoh Nilai
cv_id	Integer	Identitas unik setiap dokumen CV	1
candidate_role	String	Kategori role yang dilamar kandidat	Python Developer
cv_text	String	Teks CV kandidat (telah dibersihkan)	experienced python developer...
candidate_skills	String	Daftar skill yang dimiliki kandidat (hasil ekstraksi)	python, django, aws
bio_tags	List[Tuple]	Pasangan (token, label) hasil BIO Tagging	[('python', 'B-SKILL'), ...]
bio_skill_coverage	Float	Proporsi token bertanda skill dalam teks	0.0823

Tabel 3: Dataset Pasangan Matching (siamese_curated_data.csv)

Nama Kolom	Tipe Data	Deskripsi	Contoh Nilai
cv_text	String	Cuplikan teks CV kandidat (maks. 2.000 karakter)	experienced java developer...
job_desc_text	String	Cuplikan teks JD (maks. 2.000 karakter)	we need a backend developer...
match_label	Integer	Label kecocokan: 1 = Cocok, 0 = Tidak Cocok	1
cv_skills	String	Skill yang dimiliki kandidat	java, spring boot, docker
jd_skills	String	Skill yang dibutuhkan JD	java, kubernetes, sql
jaccard	Float	Skor kemiripan Jaccard antar daftar skill	0.2857

Tabel 4: Tabel Pemetaan Semantik (semantic_mapping_table.csv)

Nama Kolom	Tipe Data	Deskripsi	Contoh Nilai
candidate_role	String	Kategori role pada dataset CV	Python Developer
industry_domain	String	Domain JD yang relevan secara semantik	Data Scientist
is_positive_match	Integer	Penanda relasi positif (selalu bernilai 1)	1

2.6 Ringkasan Statistik Dataset

Dataset	Jumlah Record	Jumlah Role	Jumlah Kolom Kunci
Job Description (JD)	2.098	18 role industri	5
Curriculum Vitae (CV)	17.220	11 role kandidat	4
Dataset Matching (Siamese)	-	-	6
Tabel Pemetaan Semantik	28 relasi	-	3

BAB 3: ANALISIS & EKSPLORASI

3.1 Pertanyaan Bisnis

Tiga pertanyaan bisnis terukur yang menjadi landasan seluruh proses analitik pada proyek ini adalah:

- **PB 1:** Bagaimana tren kebutuhan skill IT pada berbagai role industri, serta skill apa yang bersifat universal dan spesifik pada masing-masing role?
- **PB 2:** Bagaimana karakteristik kepemilikan skill kandidat pada berbagai role IT?
- **PB 3:** Bagaimana gap skill antara kebutuhan industri dengan profil kandidat yang tersedia di pasar kerja?

3.2 Exploratory Data Analysis (EDA)

Sebelum menjawab pertanyaan bisnis, dilakukan eksplorasi awal terhadap kedua dataset untuk memahami distribusi dan karakteristik data secara umum.

Eksplorasi Dataset JD:

- Total 2.098 lowongan tersebar di 18 role industri IT.
- SQL merupakan skill yang paling sering muncul lintas role, mencerminkan dominasi kebutuhan literasi data di industri.
- Skill seperti analytics, python, testing, dan documentation juga muncul sangat konsisten, menandakan industri IT modern membutuhkan profesional yang mampu mendokumentasikan dan menjaga kualitas pekerjaannya.
- Beberapa lowongan tidak memiliki skill yang dapat diekstrak dari teks deskripsinya.

Eksplorasi Dataset CV:

- Total 17.220 dokumen CV terbagi dalam 11 role berbeda.
- SQL dan Testing mendominasi profil skill kandidat secara lintas role.
- Skill pengembangan web dasar seperti HTML, JavaScript, Java, dan CSS termasuk kelompok skill yang paling banyak dicantumkan kandidat.
- Terdapat kandidat yang tidak mencantumkan skill teknis secara eksplisit, menyebabkan nilai ekstraksi skill mereka bernilai kosong.

3.3 Jawaban atas Pertanyaan Bisnis & Narasi Hasil Visualisasi

PB-1: Tren Kebutuhan Skill IT pada Role Industri

Visualisasi 1: Rata-rata Jumlah Skill yang Dibutuhkan per Role

Analisis ini mengukur kompleksitas setiap role industri berdasarkan rata-rata jumlah skill yang dipersyaratkan dalam job posting. Warna batang pada diagram dikelompokkan menjadi tiga kategori: Kompleks (≥ 11 skill), Standar (6–10,9 skill), dan Spesifik (< 6 skill).

- **Rata-rata global:** 8,3 skill per role di seluruh profesi IT.
- **Tertinggi:** Data Scientist (13,3 skill), Web Developer (12,3 skill), Cloud Engineer (11,8 skill).
- **Terendah:** IT Consultant (3,3 skill) dan IT Operations (3,5 skill), mengindikasikan fokus pada kompetensi yang sangat spesifik.

Visualisasi 2: Signature Skill per Role Industri

Analisis ini menghitung skor spesifisitas setiap skill, seberapa unik kemunculannya pada satu role dibandingkan kemunculannya di seluruh role.

- **Data Scientist:** Skill Exploratory Data Analysis muncul secara mutlak pada 100% lowongan Data Scientist.
- **Web Developer:** TypeScript sebagai skill unik dengan skor kemunculan 88%.
- **Cyber Security Analyst:** SIEM (Security Information and Event Management) sebagai penanda utama dengan skor 86%.
- **IT Consultant:** Skor kemunculan skill unik terendah, hanya 12% untuk Microsoft Office Suite.

Visualisasi 3: Top 5 Skill per Role

Skill Universal (muncul di banyak role): Python, SQL, Analytics, Reporting, dan Excel secara konsisten muncul di lintas role, menegaskan kompetensi dasar yang universal.

Skill Spesifik per Role:

- Artificial Intelligence → AI Engineer
- Machine Learning → Machine Learning Engineer
- Business Intelligence → BI Analyst
- JavaScript → Web Developer
- Azure / AWS → Cloud Architect
- Linux / VMware → System Administrator

Kesimpulan PB-1:

Terdapat polarisasi jelas antara skill universal (frekuensi tinggi, keunikan rendah) dan signature skill (frekuensi rendah, keunikan tinggi). Perusahaan sebaiknya memprioritaskan signature skill sebagai kriteria utama dalam job posting, sementara skill universal dapat diposisikan sebagai kriteria pendukung guna mengefisiensikan proses seleksi.

PB-2: Karakteristik Kepemilikan Skill Kandidat

Visualisasi 4: Rata-rata Jumlah Skill Kandidat per Role

- **Rata-rata global:** 19,3 skill per kandidat di seluruh profesi IT.
- **Tertinggi:** Business Analyst (32,6 skill), BI Analyst (23,3 skill), Cyber Security Analyst (22,3 skill).
- **Terendah:** Cloud Engineer (8,1 skill), artinya profil yang sangat terspesialisasi.

Visualisasi 5: Signature Skill Kandidat per Role

- **Data Scientist:** A/B Testing muncul pada 100% profil kandidat.
- **Business Analyst:** ASP.NET sebagai penanda dengan skor 77%.
- **Data Engineer:** TCP/IP sebagai penanda kuat dengan skor 65%.
- **Cloud Engineer:** Skor signature skill terendah, hanya 30% untuk CI/CD.

Visualisasi 6: Top 5 Skill Kandidat per Role

- SQL dan Testing mendominasi hampir seluruh CV kandidat dengan persentase di atas 50% pada banyak role.
- HTML dan JavaScript masuk dalam kelompok skill terpopuler, mencerminkan fondasi pengembangan web yang kuat pada mayoritas kandidat IT.

Kesimpulan PB-2:

Perusahaan disarankan menerapkan strategi screening berbasis signature skill, memfokuskan filter awal pada skill spesifik dengan keunikan tinggi dibandingkan mengandalkan skill universal seperti SQL yang dicantumkan hampir semua kandidat.

PB-3: Analisis Gap Skill — Kebutuhan Industri vs Profil Kandidat

Metodologi Kalkulasi Gap Score:

Gap score dihitung menggunakan formula normalisasi berbasis persentase kemunculan relatif:

$$\text{Gap Score} = 100 - ((\text{cv_pct} / \text{jd_pct}) \times 100)$$

jd_pct = persentase kemunculan skill dalam dataset JD

cv_pct = persentase kemunculan skill dalam dataset CV

Nilai positif = kekurangan suplai kandidat relatif terhadap permintaan industri

Temuan: Top 5 Skill dengan Gap Tertinggi:

Peringkat	Skill	Gap Score
1	Node.js	98,8%
2	A/B Testing	98,0%
3	Looker	97,3%
4	Operations Research	96,8%
5	Artificial Intelligence	96,7%

Kesenjangan yang sangat tinggi pada skill-skill di atas mengindikasikan bahwa laju adopsi teknologi spesifik di industri bergerak jauh lebih cepat dibandingkan pembaruan keahlian yang dimiliki oleh mayoritas kandidat.

Temuan: Top 5 Skill dengan Gap Terendah (Paling Selaras):

Peringkat	Skill	Gap Score
1	Switching	1,0%
2	SIEM	1,8%
3	Elasticsearch	2,0%
4	Incident Management	2,5%
5	C	3,2%

Kecilnya angka gap ini menunjukkan bahwa suplai kandidat di pasar kerja sudah sangat memenuhi standar kebutuhan yang dicari oleh perusahaan untuk kompetensi tersebut.

Kesimpulan PB-3:

- **Bagi Kandidat:** Prioritaskan upskilling pada teknologi dengan gap di atas 90% (Node.js, A/B Testing, Looker, Artificial Intelligence) untuk meningkatkan daya saing.
- **Bagi Perusahaan:** Gunakan data defisit skill untuk merancang program rekrutmen yang lebih terarah, atau menyusun program pelatihan internal (reskilling) guna menjembatani kelangkaan talenta kritis.

BAB 4: IMPLEMENTASI & DEPLOYMENT

4.1 Pengembangan Dashboard Interaktif (Streamlit)

Dashboard analitik interaktif dikembangkan menggunakan Streamlit dengan nama aplikasi ResuMy. Pengembangan dilakukan dalam file tunggal dashboard.py yang mencakup seluruh logika data, pemrosesan, dan presentasi visual.

4.1.1 Arsitektur Aplikasi

Aplikasi dibangun dengan pola arsitektur single-file multi-page menggunakan mekanisme navigasi berbasis st.session_state. Terdapat tiga halaman utama yang dapat diakses melalui sidebar navigasi:

Kode Halaman	Nama Halaman	Pertanyaan Bisnis
industri	 Tren Kebutuhan Industri	PB-1
kandidat	 Karakteristik Kandidat	PB-2
gap	 Analisis Gap Skill	PB-3

4.1.2 Komponen Teknis Utama

Manajemen Data:

Data dimuat dari Google Drive menggunakan library gdown dan di-cache menggunakan dekorator @st.cache_data untuk menghindari pemuatan ulang yang tidak perlu dan mempercepat responsivitas aplikasi.

```
@st.cache_data(show_spinner="Memuat data...")
def load_data():
    df_jd = pd.read_csv(gdrive_url(FILE_ID_JD))
    # ... proses komputasi agregasi dan kalkulasi
    return { "df_jd": df_jd, "df_cv": df_cv, ... }
```

Visualisasi Interaktif:

Seluruh visualisasi dibangun menggunakan Plotly (plotly.graph_objects) untuk menghasilkan grafik batang horizontal (horizontal bar chart) yang interaktif. Fungsi-fungsi helper modular dikembangkan untuk menjaga konsistensi tampilan:

- hbar_chart(): Fungsi generik untuk membuat grafik batang horizontal.
- make_top_n_chart(): Menampilkan Top-N skill untuk role yang dipilih.
- make_jumlah_skill_chart(): Menampilkan rata-rata jumlah skill per role.
- make_signature_chart(): Menampilkan signature skill dan skor spesifisitasnya.
- make_gap_chart(): Menampilkan analisis gap skill antara industri dan kandidat.

Elemen Interaktif:

- st.selectbox: Filter pemilihan role industri/kandidat dan jumlah Top-N.
- st.metric: Kartu KPI ringkasan yang menampilkan total role, posting/kandidat, dan unique skill.
- Layout responsif menggunakan st.columns untuk tampilan paralel dua panel.

4.1.3 Desain Visual & Tema

Aplikasi menggunakan tema gelap (dark theme) yang konsisten dengan palet warna merah-hitam seperti warna Coding Camp 2026 Powered by DBS Foundation. Kustomisasi antarmuka dilakukan melalui custom CSS injection menggunakan st.markdown(..., unsafe_allow_html=True).

Token Warna	Nilai HEX	Penggunaan
ACCENT	#E4002B	Warna utama/aksen (merah)
BG_PLOT	#161616	Latar belakang area grafik
GRID_COLOR	#2a2a2a	Warna garis grid grafik

TEXT_COLOR	#CCCCCC	Warna teks utama
------------	---------	------------------

4.1.4 Fitur per Halaman Dashboard

Halaman 1: Tren Kebutuhan Industri:

- Kartu KPI: Total Role Industri, Total Job Postings, Unique Skills.
- Filter interaktif: pilihan role industri dan Top-N skill.
- Grafik Top-N Skill per Role yang dipilih (dinamis).
- Panel dua kolom: Rata-rata jumlah skill (kiri) dan Signature Skill (kanan).
- Panel Kesimpulan & Rekomendasi.

Halaman 2: Karakteristik Kandidat:

- Kartu KPI: Total Role Kandidat, Total Kandidat, Unique Skills.
- Filter interaktif: pilihan role kandidat dan Top-N skill.
- Grafik Top-N Skill Kandidat per Role (dinamis).
- Panel dua kolom: Rata-rata jumlah skill kandidat (kiri) dan Signature Skill (kanan).
- Panel Kesimpulan & Rekomendasi.

Halaman 3: Analisis Gap Skill:

- Kartu KPI: Total Skill dianalisis, Gap Terbesar (beserta nama skill), Gap Terkecil.
- Filter interaktif: Top-N untuk tampilan gap.
- Panel dua kolom: Top-N Gap Tertinggi (kiri) dan Top-N Gap Terendah (kanan).
- Panel Action Items untuk Kandidat dan Perusahaan.

4.2 Deployment ke Streamlit Cloud

4.2.1 Arsitektur Deployment

Aplikasi ResuMy di-deploy menggunakan platform Streamlit Community Cloud (share.streamlit.io), yang menyediakan layanan hosting gratis berbasis cloud yang terintegrasi langsung dengan repositori GitHub.

4.2.2 Komponen Infrastruktur

Komponen	Layanan	Keterangan
Hosting Aplikasi	Streamlit Community Cloud	Platform PaaS gratis untuk aplikasi Streamlit
Source Control	GitHub	Repositori kode sumber
Penyimpanan Data	Google Drive	Dataset JD dan CV diakses via URL publik
Runtime	Python 3.x (managed)	Dikelola otomatis oleh Streamlit Cloud
Dependency Management	requirements.txt	Daftar library yang dibutuhkan aplikasi

4.2.3 Konfigurasi Aplikasi

Konfigurasi tampilan aplikasi didefinisikan melalui `st.set_page_config()`:

```
st.set_page_config(
    page_title="ResuMy",
    layout="wide",
    initial_sidebar_state="expanded",
)
```

4.2.4 Strategi Pengambilan Data di Cloud

Karena Streamlit Community Cloud tidak menyediakan penyimpanan persisten, data diambil secara dinamis dari Google Drive pada saat pertama kali aplikasi diakses oleh pengguna. Mekanisme caching `@st.cache_data` memastikan data hanya diunduh sekali per sesi, sehingga performa aplikasi tetap optimal meskipun bersumber dari layanan eksternal.

BAB 5: KESIMPULAN

5.1 Ringkasan Pencapaian Proyek

Proyek Capstone ResuMy telah berhasil diselesaikan mencakup seluruh tahap pipeline Data Science, mulai dari identifikasi masalah hingga penyajian hasil analisis melalui platform yang dapat diakses secara publik.

Tahap	Aktivitas	Status
Problem Discovery	Identifikasi permasalahan utama, penetapan solusi analitik	✓ Selesai
Data Gathering	3 sumber data terpadu: 2.098 JD + 17.220 CV	✓ Selesai
Data Assessing	Penilaian kualitas, tipe data, dan missing value pada 4 tabel	✓ Selesai
Data Cleaning	Pembersihan teks, pemetaan role, deduplikasi, train-test split	✓ Selesai
Skill Extraction & NER	Daftar 150+ entitas skill, regex-based NER, BIO Tagging	✓ Selesai
Data Dictionary	5 tabel data terdokumentasi lengkap	✓ Selesai
EDA & Visualisasi	7 visualisasi menjawab 3 pertanyaan bisnis	✓ Selesai
Dashboard Development	3 halaman interaktif dengan Streamlit + Plotly	✓ Selesai
Deployment	Aplikasi publik via Streamlit Cloud	✓ Selesai

5.2 Temuan Kunci

Berdasarkan seluruh rangkaian analisis yang telah dilakukan, tiga temuan kunci yang paling signifikan dari proyek ini adalah:

- **SQL pada Industri IT:** SQL secara konsisten muncul sebagai skill paling dibutuhkan industri sekaligus paling banyak dimiliki kandidat, menegaskan posisinya sebagai kompetensi dasar (baseline competency) yang tidak dapat dinegosiasikan di hampir seluruh role IT modern.
- **Kesenjangan Skill Kritis pada Teknologi Mutakhir:** Terdapat kesenjangan yang sangat besar (>95%) antara permintaan industri dan ketersediaan kandidat pada teknologi-teknologi mutakhir seperti Node.js, A/B Testing, Looker, dan Artificial Intelligence. Ini menandakan urgensi bagi kandidat untuk melakukan upskilling pada domain ini.
- **Dualisme Profil Kandidat:** Kandidat secara rata-rata memiliki jauh lebih banyak skill (rata-rata 19,3) dibandingkan yang diminta industri (rata-rata 8,3), namun skill yang mereka miliki tidak selalu selaras. Ini mengonfirmasi bahwa masalah bukan pada kuantitas, melainkan pada relevansi kompetensi.

5.3 Rekomendasi Strategis

Bagi Kandidat Pencari Kerja:

- Fokuskan program upskilling pada skill dengan gap tertinggi (Node.js, A/B Testing, Looker, Artificial Intelligence) untuk meningkatkan daya saing secara signifikan di pasar kerja.
- Pelajari signature skill yang spesifik untuk role yang dituju, bukan hanya mengandalkan skill universal seperti SQL atau Excel yang sudah dimiliki oleh hampir semua pesaing.

Bagi Perusahaan dan Tim Rekrutmen:

- Terapkan strategi signature skill-based screening pada tahap seleksi awal CV untuk menghasilkan shortlist yang lebih berkualitas dan efisien.
- Manfaatkan data gap skill untuk merancang program pelatihan internal (reskilling/upskilling) guna menjembatani kelangkaan talenta pada kompetensi-kompetensi kritis yang sulit ditemukan di pasar.

5.4 Keterbatasan dan Saran Pengembangan ke Depan

Keterbatasan Proyek Saat Ini:

- Dataset JD bersumber dari data statis dan tidak mencerminkan kondisi pasar kerja secara real-time.
- Ekstraksi skill berbasis keyword matching mungkin tidak mampu menangkap ekspresi skill yang tertulis dengan cara tidak baku atau dalam konteks bahasa yang berbeda.

Saran Pengembangan:

- Mengintegrasikan pipeline pengambilan data JD secara otomatis (web scraping) dari platform seperti LinkedIn dan Glints untuk mendapatkan data yang lebih mutakhir.
-